

**T.C.
SELÇUK ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ
BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI
(YÜKSEK LİSANS — TEZLİ)**

**BÜYÜK DİL MODELLERİ DERSİ
FINAL PROJESİ RAPORU**

**TÜRKÇE TIBBİ TRIAJ VE BÖLÜM YÖNLENDİRME GÖREVİ İÇİN
KÜÇÜK DİL MODELLERİNİN İNCE AYARI:
SmolLM2-360M, Qwen2.5-1.5B ve Gemma-4-E2B
KARŞILAŞTIRMALI BENCHMARK ÇALIŞMASI**

Hazırlayanlar

Ebubekir BAYAR — 258273002001

Furkan KOCATAŞ — 258273002008

KONYA — 2026

ÖZET

Bu çalışma, Türkçe doğal dilde ifade edilen hasta semptomlarına dayanarak (i) acil servis triaj seviyesini (Yeşil / Sarı / Kırmızı) ve (ii) hastane bölüm yönlendirmesini birlikte üreten bir Küçük Dil Modeli (Small Language Model — SLM) sistemini önermektedir. Çalışmanın temel motivasyonu, sınırlı donanım kaynaklarına sahip ortamlarda dahi çalıştırılabilecek, açık kaynak parametre verimli ince ayar yöntemleriyle eğitilmiş ve klinik açıdan kritik güvenlik metrikleri üzerinden değerlendirilen bir karar destek prototipi geliştirmektir.

Çalışmada zorunlu benchmark protokolüne uygun olarak SmolLM2-360M, Qwen2.5-1.5B ve Gemma-4-E2B (yaklaşık 2 milyar efektif parametre) modelleri kullanılmıştır. Eğitim verisi olarak Hugging Face üzerinden erişilebilir olan alibayram/doktorsitesi veri kümesinden 5.000 örnek alınmış; etiketleme, Kaggle Türkçe Tıbbi Acil Triaj veri kümesinden çıkarılan ayırt edici anahtar kelimeler üzerinden inşa edilen üç katmanlı kural tabanlı bir sınıflandırıcı ile gerçekleştirilmiştir. Veri 80/10/10 oranlarıyla, triaj ve bölüm çiftine göre stratifiye edilerek bölünmüştür (eğitim: 3.972, doğrulama: 475, test: 553; tohum=42).

Modeller, parametre verimli ince ayar yöntemleri olan QLoRA (4-bit NF4) ve LoRA (bf16) ile eğitilmiş; ayrıca eğitim setinde gözlemlenen ciddi sınıf dengesizliği (Kırmızı sınıfı %4,1) için temiz bir yeniden örnekleme (Kırmızı 4× çoğaltma) müdahalesi uygulanmıştır. Toplamda dokuz farklı değerlendirme yapılandırması test edilmiştir: üç zero-shot, dört orijinal ince ayar, dengeli ince ayar ve iki katmanlı (cascade) çıkarım. Değerlendirmede sınıflandırma metrikleri (Accuracy, Macro-F1, Weighted-F1) yanı sıra klinik güvenlik metrikleri olarak False Green Rate (FGR) ve Kırmızı sınıfı için False Negative Rate (FNR-Red) raporlanmıştır.

Bulgular dört ana noktada özetlenebilir: (1) Tüm zero-shot yapılandırmalar JSON şemasını ve Türkçe etiket üretimini başarısızca yerine getirmiş, accuracy ≈ 0 değerinde kalmıştır; (2) İlk fine-tuning denemelerinde tüm modeller yaklaşık %62,4 doğruluk seviyesine yakınsamıştır ve bu değer, test kümesinde Sarı sınıfının oranıyla aynıdır — modeller Sarı sınıfa çökmüş, FNR-Red değeri 1,000 olmuştur; (3) Kırmızı sınıfının 4 kat çoğaltıldığı dengeli eğitim sonrası Qwen2.5-1.5B modelinin Macro-F1 değeri 0,256'dan 0,390'a (%52 göreceli iyileşme) yükselmiş, FNR-Red ise 1,000'den 0,529'a (-0,471 mutlak) düşmüştür; (4) L1→L2→L3 cascade mimarisi, her iki yapılandırmada da (v1 ve format-düzeltilme uygulanmış v2) tek başına Qwen-balanced model ile aynı sonuçlara ulaşmış ve yaklaşık 11 kat ek gecikme getirmesine karşın katma değer üretmemiştir.

Çalışma, küçük dil modellerinin Türkçe medikal görevlerde Hugging Face Hub açık kaynak modelleriyle ulaşılabilir bir başlangıç sınırını ortaya koymakta; sınıf dengesizliği müdahalesinin gerekliliğini ve klinik dağıtım için FNR-Red eşliğinin (literatürde $<5-10$) bu prototip ile karşılanamadığını şeffaflıkla raporlamaktadır. Önerilen sistem bir araştırma prototipidir; klinik kullanım yetkin doktor doğrulaması ve daha güçlü kayıp düzeyinde dengeleme yöntemleri (focal loss, ağırlıklandırılmış CE) olmaksızın önerilmemektedir.

Anahtar Kelimeler: Türkçe NLP, Tıbbi Triaj, Küçük Dil Modelleri, QLoRA, LoRA, Sınıf Dengesizliği, Cascade Inference, Klinik Karar Destek.

ABSTRACT

This study introduces a Small Language Model (SLM) based decision-support prototype for Turkish emergency department triage. Given a free-text symptom description in Turkish, the system jointly produces (i) a triage acuity level (Green / Yellow / Red) and (ii) a hospital department routing label. The motivation is to enable open-source, parameter-efficient training of compact models that can run on consumer-grade hardware while being evaluated through clinical safety metrics.

Following a mandated benchmarking protocol, three open-weight models are evaluated: SmolLM2-360M, Qwen2.5-1.5B, and Gemma-4-E2B (~2B effective parameters). The training corpus consists of 5,000 samples drawn from the alibayram/doktorsitesi Hugging Face dataset, labeled through a three-stage rule-based pipeline derived from the Kaggle Turkish Medical Emergency Triage dataset. The data is stratified-split 80/10/10 (3,972 / 475 / 553) under a fixed seed of 42.

Models are fine-tuned with QLoRA (4-bit NF4) and LoRA (bf16). To address severe class imbalance (Red class only 4.1% of the training set), a clean 4× oversampling intervention is applied to the Red class. Nine evaluation runs are performed: three zero-shot baselines, four standard fine-tunes, one balanced-data fine-tune, and two cascade configurations. Reported metrics include classification performance (Accuracy, Macro-F1, Weighted-F1) along with clinical safety indicators False Green Rate (FGR) and Red-class False Negative Rate (FNR-Red).

Key findings: (1) All zero-shot runs fail to produce valid JSON in Turkish triage labels ($\text{acc} \approx 0$); (2) Naive fine-tuning yields a uniform ~ 0.624 accuracy that exactly matches the test-set Yellow proportion — every model collapses to predicting Yellow with $\text{FNR-Red} = 1.0$; (3) Balanced training lifts Qwen2.5-1.5B Macro-F1 from 0.256 to 0.390 (a 52% relative improvement) and reduces FNR-Red from 1.000 to 0.529 (a 0.471 absolute reduction); (4) The L1→L2→L3 cascade architecture, even after a prompt-format remediation (v2), produces virtually bit-identical predictions to the single Qwen-balanced model while incurring an $\sim 11\times$ latency penalty.

Although the prototype demonstrates a clear improvement direction, the FNR-Red of 0.529 remains far above the clinically acceptable threshold ($< 5\text{--}10\%$ in the literature) and the system is not recommended for production deployment without further loss-level imbalance correction and clinician-validated labeling.

Keywords: Turkish NLP, Medical Triage, Small Language Models, QLoRA, LoRA, Class Imbalance, Cascade Inference, Clinical Decision Support.

İÇİNDEKİLER

ÖZET.....	i
ABSTRACT.....	ii
ŞEKİLLER LİSTESİ.....	iv
TABLolar LİSTESİ.....	v
KISALTMALAR.....	vi
1. GİRİŞ.....	1
1.1. Problem Tanımı.....	1
1.2. Motivasyon.....	2
1.3. Bilimsel Katkıları.....	2
1.4. Rapor Yapısı.....	3
2. LİTERATÜR TARAMASI.....	4
2.1. Tıbbi Triage Sistemleri.....	4
2.2. NLP Tabanlı Triage.....	4
2.3. Türkçe Medikal NLP.....	5
2.4. Küçük Dil Modelleri Ailesi.....	6
2.5. Parametre Verimli İnce Ayar.....	7
2.6. Sınıf Dengesizliği Müdahaleleri.....	8
2.7. Cascade ve Hiyerarşik Çıkarım.....	8
3. MATERYAL VE YÖNTEM.....	9
3.1. Donanım ve Yazılım Ortamı.....	9
3.2. Veri Setleri.....	10
3.3. Etiketleme Protokolü.....	11
3.4. Veri Bölme Protokolü.....	12
3.5. Model Seçimi.....	13
3.6. İnce Ayar Stratejisi.....	14
3.7. Prompt Şablonu.....	14
3.8. Değerlendirme Metrikleri.....	15
3.9. Sınıf Dengesizliği Müdahalesi.....	16

4. DENEYSEL DÜZEN.....	17
5. SONUÇLAR.....	19
5.1. Eğitim Süreç Metrikleri.....	19
5.2. Zero-shot Baseline.....	20
5.3. Fine-tuned Performans.....	21
5.4. Confusion Matrix Analizi.....	22
5.5. Sınıf Bazlı Performans.....	23
5.6. Sınıf Dengesizliği Müdahalesi Etkisi.....	24
5.7. Pareto Analizi.....	25
5.8. Gecikme - Performans Dengesi.....	26
5.9. Cascade Çıkarım Sonuçları.....	27
5.10. Kaynak Tüketimi.....	28
5.11. Standart Sonuç Tablosu.....	29
6. HATA ANALİZİ.....	30
7. TARTIŞMA.....	33
8. SINIRLAMALAR.....	35
9. SONUÇ VE GELECEK ÇALIŞMALAR.....	36
KAYNAKLAR.....	37
EKLER.....	39
EK A. Hiperparametre Tablosu.....	39
EK B. Model Kartları.....	40
EK C. Prompt Şablonları.....	41
EK D. Reproducibility Index.....	42

ŞEKİLLER LİSTESİ

Şekil 1. Tıbbi Triage Sistemi Genel Boru Hattı.....	10
Şekil 2. Veri Bölme Sonrası Triage Sınıf Dağılımı.....	12
Şekil 3. Sınıf Dengesizliği: Orijinal vs Oversample Edilmiş Eğitim Seti.....	16
Şekil 4. Etiketli Veri Setinde En Yoğun Tıbbi Bölümler.....	13
Şekil 5. Modellerin Eğitim Sırasında Kayıp Eğrileri.....	19
Şekil 6. Modellerin Final eval_loss Karşılaştırması.....	19
Şekil 7. Zero-shot ve Fine-Tuned Triage Performansı.....	20
Şekil 8. Tüm Çalışmalarda Macro-F1 Karşılaştırması.....	21
Şekil 9. 9 Çalışmaya ait Confusion Matrix Karşılaştırması.....	22
Şekil 10. Sınıf Bazlı F1 Skoru.....	23
Şekil 11. Sınıf Dengesizliği Müdahalesi Radar Karşılaştırması.....	24
Şekil 12. Pareto Eğrisi: Model Boyutu vs Macro-F1.....	25
Şekil 13. Gecikme - Performans Dengesi.....	26
Şekil 14. JSON Parse Başarı Oranı.....	26
Şekil 15. Eğitim ve Inference Aşamasında Kaynak Tüketimi.....	28
Şekil 16. Cascade Mimarisinde Katman Dağılımı.....	27
Şekil 17. Sınıf Dengesizliği Müdahalesi: Kırmızı Sınıfı Yakalama Etkisi.....	24
Şekil 18. Hata Taksonomisi.....	31

TABLÖLAR LİSTESİ

Tablo 3.1. Veri Setlerinin Özet Bilgileri.....	10
Tablo 3.2. Veri Bölme İstatistikleri.....	12
Tablo 3.3. Model Mimari Özet Bilgileri.....	13
Tablo 3.4. Eğitim Hiperparametreleri.....	14
Tablo 5.1. Eğitim Süreç Metrikleri.....	19
Tablo 5.2. Zero-shot Triaj Sonuçları (n=553).....	20
Tablo 5.3. Fine-tuned Triaj ve Bölüm Sonuçları.....	21
Tablo 5.4. Sınıf Dengesizliği Müdahalesi Karşılaştırması (Qwen2.5-1.5B).....	24
Tablo 5.5. Cascade v1 ve v2 Sonuçları.....	27
Tablo 5.6. Standart Sonuç Tablosu (Benchmark Protokolü).....	29
Tablo A.1. Tam Hiperparametre Listesi.....	39

KISALTMALAR

LLM	Large Language Model — Büyük Dil Modeli
SLM	Small Language Model — Küçük Dil Modeli
LoRA	Low-Rank Adaptation — Düşük Rütbeli Adaptasyon
QLoRA	Quantized Low-Rank Adaptation — Nicelendirilmiş LoRA
NF4	Normal Float 4-bit nicelendirme şeması
PEFT	Parameter-Efficient Fine-Tuning — Parametre Verimli İnce Ayar
CE	Cross Entropy — Çapraz Entropi
F1	F1 Score — Hassasiyet ve Geri Çağırmanın Harmonik Ortalaması
FGR	False Green Rate — Yanlış Yeşil Oranı
FNR-Red	False Negative Rate (Red) — Kırmızı Sınıfında Hatalı Negatif Oranı
ESI	Emergency Severity Index
MTS	Manchester Triage System
TF-IDF	Term Frequency - Inverse Document Frequency
BERT	Bidirectional Encoder Representations from Transformers
VRAM	Video RAM — GPU bellek
HF	Hugging Face
ED	Emergency Department — Acil Servis
SFT	Supervised Fine-Tuning — Gözetimli İnce Ayar
MoE	Mixture of Experts

1. GİRİŞ

1.1. Problem Tanımı

Acil servis (Emergency Department — ED) triajı, hastaların aciliyet durumuna göre önceliklendirildiği ve uygun klinik birime yönlendirildiği kritik bir süreçtir. Türkiye'de 2023 yılında acil servislere yapılan yıllık başvuru sayısı 130 milyonun üzerindedir; bu rakam Türkiye nüfusunun yaklaşık 1,5 katına karşılık gelmekte ve OECD ortalamasının çok üzerinde seyretmektedir. Yoğun başvuru hacmi, triaj hemşiresi başına düşen vaka sayısının artmasına ve dolayısıyla karar süresinde sıkışmaya yol açmaktadır. Diğer taraftan, hasta hekim erişimi noktasında doğru bölüm yönlendirmesi yapılmaması ek konsültasyon ve gereksiz radyolojik incelemelere neden olabilmektedir.

Bu çalışmada ele alınan problem; bir hastanın doğal Türkçe ile ifade ettiği semptom metnine dayanarak iki çıktıyı eş zamanlı üretebilen bir Küçük Dil Modeli (SLM) tabanlı karar destek prototipinin geliştirilmesidir. Üretilen ilk çıktı, üç sınıflı triaj acuity etiketidir: Yeşil (poliklinik düzeyinde, ertelenebilir), Sarı (hekim değerlendirmesi gerekli ama acil değil), Kırmızı (acil müdahale gerekli). İkinci çıktı, semptom örüntüsüne en uygun klinik bölüm önerisidir (örneğin Kardiyoloji, Nöroloji, Dahiliye, Çocuk Sağlığı vb.). Sistem, klinik karar verme yetkisine sahip olmamakla birlikte; akıllı telefon, kiosk veya çağrı merkezi gibi düşük maliyetli kanallarda hastanın ön yönlendirmesi için bir araç olarak konumlandırılmaktadır.

Görev, doğal dil işleme literatüründe çok etiketli sınıflandırma probleminin özel bir hâli olup; klinik uygulanabilirliğinin sağlanabilmesi için klasik doğruluk metriklerinin yanı sıra yanlış-yeşil oranı (False Green Rate — FGR) ve Kırmızı sınıfı için yanlış-negatif oranı (FNR-Red) gibi güvenlik metrikleri ön plana çıkmaktadır. Bu metriklerin minimize edilmesi, bir Kırmızı vakanın yanlışlıkla Yeşil sınıfına atanmasının yaratabileceği geri döndürülemez sonuçların önüne geçilebilmesi açısından kritiktir.

1.2. Motivasyon

Tıbbi NLP literatüründe önerilen ileri seviye sistemlerin önemli bir kısmı, yüz milyarlarca parametreye sahip kapalı kaynak modellere (GPT-4, Med-PaLM-2, Claude 3 vb.) dayanmaktadır. Bu modellerin Türkiye'deki kamu sağlık altyapısında doğrudan dağıtılması üç temel engelle karşılaşmaktadır: (i) hastaya özel verinin yurt dışı bulut altyapısına gönderilmesinin KVKK ve veri yerelliği açısından kısıtlamalar doğurması; (ii) çağrı başına maliyetin (API ücretlendirmesi) ölçeğin gerektirdiği binlerce çağrıda bütçe baskısı oluşturmaları; (iii) gerçek zamanlı çalışma için çevrimdışı çalışabilirlik ihtiyacı.

Küçük Dil Modelleri (SLM) bu üç engele karşı sistematik bir alternatif sunmaktadır. 1–2 milyar parametre aralığındaki açık kaynak modeller, parametre verimli ince ayar yöntemleriyle (LoRA, QLoRA) tek bir tüketici GPU'sunda (örneğin RTX 4070, 12 GB) eğitilebilmekte ve aynı donanımda saniyenin altında bir gecikme ile çıkarım üretebilmektedir. Üstelik, bu modellerin ağırlıkları ve yardımcı verileri yerel altyapıda tutulabildiği için veri yerelliği ihlal edilmemektedir.

Bu çalışmanın diğer bir motivasyonu, ders kapsamında belirlenen ortak benchmark protokolüne katkı sağlamaktır. Tüm projelerin sonuçlarının bir araya getirilerek 'Small Language Models for Turkish NLP: A Fine-Tuning Benchmark' başlıklı kapsamlı bir benchmark çalışmasına dönüştürülmesi planlandığından;

metodolojik tutarlılık, model seti zorunluluğu (SmolLM2, Qwen2.5, Gemma) ve değerlendirme protokolü (zero-shot vs fine-tuned, standart sonuç tablosu) bu rapor genelinde korunmuştur.


1.3. Bilimsel Katkılar

Çalışmanın akademik literatüre sağladığı temel katkılar aşağıda sıralanmıştır:

1. Türkçe medikal triaj görevinde üç farklı SLM ailesinin (SmolLM2, Qwen2.5, Gemma) yan yana karşılaştırılmasının ayrıntılı raporu sunulmuştur. Türkçe medikal NLP literatüründe bu üç modelin birlikte değerlendirildiği kamuya açık bir karşılaştırma bilgi topluluğu tarafımızca tespit edilememiştir.
2. Aynı temel modelin (Qwen2.5-1.5B) iki farklı parametre verimli ince ayar yapılandırmasında (QLoRA 4-bit ve LoRA bf16) eğitilerek; sınırlı VRAM ortamında bf16 LoRA'nın hem hız hem de kayıp metrikleri açısından QLoRA'ya kıyasla üstünlüğü sayısal olarak gösterilmiştir.
3. Sınıf dengesizliği problemi karşısında uygulanan iki bağımsız müdahalenin (kural gevşetme — başarısız; temiz oversample — başarılı) deneysel sonuçları şeffaflıkla raporlanmıştır.
4. Üç katmanlı bir cascade çıkarım mimarisi (L1: SmolLM2, L2: Qwen2.5, L3: Gemma-4) inşa edilmiş ve bu yapının basit konfigürasyonlarda tek modele kıyasla katma değer üretmediğine dair negatif bulgu literatüre kazandırılmıştır.
5. FGR ve FNR-Red gibi klinik güvenlik metrikleri ile birlikte yapılan değerlendirme, yalnızca doğruluk üzerinden raporlamanın bu görev için yetersiz olduğunu açıkça ortaya koymuştur.

1.4. Rapor Yapısı

İkinci bölümde tıbbi triaj, Türkçe medikal NLP ve parametre verimli ince ayar literatürüne ait kısa bir tarama sunulmaktadır. Üçüncü bölümde donanım ortamı, veri kümeleri, etiketleme protokolü, model seçim gerekçeleri, ince ayar stratejisi, prompt şablonu ve değerlendirme metrikleri ayrıntılı olarak ele alınmaktadır. Dördüncü bölüm deneysel düzeni ve sınıf dengesizliği müdahalesinin tasarımını kapsamaktadır. Beşinci bölüm, çalışmanın omurgasını oluşturan sonuçları on bir alt başlık altında raporlamaktadır. Altıncı bölümde sistematik bir hata analizi gerçekleştirilmiş; yedinci bölümde bulgular literatür ışığında tartışılmıştır. Sekizinci ve dokuzuncu bölümler sınırlamaları, sonuçları ve gelecek çalışma maddelerini içermektedir. Dört ek başlığı altında hiperparametre tabloları, model kartları, prompt şablonları ve yeniden üretilebilirlik bilgileri sunulmaktadır.



Şekil 1. Tıbbi triaj sistemi genel boru hattı.

2. LİTERATÜR TARAMASI

2.1. Tıbbi Triağ Sistemleri

Modern acil servis triağı, 1960'lardan itibaren askeri tıp alanında ortaya çıkan ve sivil acil servislere uyarlanan üç ana sistem etrafında şekillenmiştir. Manchester Triage System (MTS), Birleşik Krallık'ta 1990'larda geliştirilmiş olup hastaları beş kategoride önceliklendirmektedir: kırmızı (acil), turuncu, sarı, yeşil, mavi. Emergency Severity Index (ESI), Amerika Birleşik Devletleri'nde Wuerz ve arkadaşları (1998) tarafından tanıtılmış; klinisyenin hayati tehlike, kaynak tüketimi ve yaşamsal bulgu eşik değerlerini birlikte değerlendirmesini gerektirmektedir. Türkiye Sağlık Bakanlığı tarafından 2009'dan itibaren uygulanan üç renkli (Yeşil/Sarı/Kırmızı) sistem ise hızlı uygulanabilirliği nedeniyle yaygın olarak benimsenmiştir [1, 2].

Doğru triağ, hastaların hayatta kalma oranıyla doğrudan ilişkilidir. Akut miyokard enfarktüsü, iskemik inme ve sepsis gibi durumlarda zaman kritik öneme sahiptir; her dakikalık gecikme klinik sonuçları olumsuz etkilemektedir. Buna karşın insan operatörler arasındaki triağ tutarlılığı (inter-rater agreement) bazı çalışmalarda 0,55–0,70 arasında raporlanmaktadır [3]. Bu durum, makine destekli karar destek araçlarının potansiyel rolünü ortaya koymaktadır.

2.2. NLP Tabanlı Triağ Çalışmaları

İngilizce literatürde elektronik sağlık kayıtları (EHR) üzerinden NLP tabanlı triağ tahmini için yapılan çalışmalar 2000'li yıllarda başlamış olup, başlangıçta TF-IDF ve karar ağaçları tabanlı yaklaşımları kullanmıştır [4]. 2018 sonrası dönemde BioBERT [5], ClinicalBERT [6] ve PubMedBERT [7] gibi domain-adapted transformer mimarilerinin tanıtılmasıyla birlikte alanın doğruluğu belirgin ölçüde artmıştır. Sterling ve arkadaşları (2019) ESI tahmini için BioBERT temelli bir sınıflandırıcının metin-tabanlı semptom girdisinden 0,84 AUROC değerine ulaştığını raporlamıştır.

Daha güncel çalışmalar büyük dil modellerini bu göreve uyarlamaya başlamıştır. Med-PaLM (Singhal et al., 2023) [8] ve Med-Gemini (Saab et al., 2024) [9], Amerika Birleşik Devletleri tıp lisans sınavı USMLE'de hekim seviyesinde başarı raporlarken; bu modellerin triağ alt görevinde performansı henüz az sayıda çalışmada doğrulanmıştır. Açık kaynak Llama-2-7B veya Mistral-7B üzerine LoRA ile ince ayarlama deneyleri 2024 itibarıyla literatüre girmeye başlamıştır.

2.3. Türkçe Medikal NLP

Türkçe medikal NLP alanı, İngilizce karşısına kıyasla belirgin olarak az incelenmiş bir alandır. Yararlanılabilecek temel kaynaklardan biri BERTürk [10] modelleridir; 2020'de tanıtılan bu modeller Türkçe Wikipedia ve farklı korpuslarda eğitilmiş olup tıp metinlerinde tatmin edici performans gösterememektedir. Onan ve arkadaşları (2021), Türkçe TweetEval-Health alt göreviyle BERTürk'ü değerlendirmiş ve İngilizce muadillere göre 5–8 puanlık F1 düşüşü gözlemlemiştir.

Kamuya açık Türkçe medikal veri kümelerinden alibayram/doktorsitesi (2023, Hugging Face) hekim-hasta soru-cevap çiftlerini içermekte olup yaklaşık 187 bin kayıt sunmaktadır. alibayram/turkish-hospital-medical-articles ise 14 farklı hastane web sayfasından derlenmiş yaklaşık 24 bin makale içeren bir domain

corpus'udur (CC BY 4.0). turkerberkdonmez/TUSGPT-TR-Medical-Dataset-v1, TUS düzeyinde soru-cevap çiftleri içermesiyle akademik medikal bilgiyi modele aktarmak için uygun bir kaynaktır. Bu çalışmada doktorsitesi veri seti birincil kaynak olarak seçilmiş; etiket sinyalinin güçlendirmek üzere Kaggle'dan elde edilen Türkçe Tıbbi Acil Triage veri kümesi kural çıkarımı için kullanılmıştır.

2.4. Küçük Dil Modelleri Ailesi

Küçük Dil Modelleri (SLM), genelde 100 milyon ile 4 milyar parametre aralığındaki ağırlık dosyaları ve onlarla birlikte gelen tokenizer kümesi olarak tanımlanmaktadır. Bu çalışmada zorunlu protokol kapsamında üç farklı aileden temsilciler kullanılmıştır:

SmolLM2-360M (Hugging Face, 2024): Eğitim verisi olarak FineWeb-Edu, OWM ve InfiniWeb karışımı kullanılmış; toplam 4 trilyon tokenle önceden eğitilmiş 32 katmanlı transformer ailesindendir. Hedef kullanım edge cihazlardır (Raspberry Pi, mobil) ve INT4 nicelendirme ile yaklaşık 200 MB'a sıkıştırılabilmektedir. Çok dilli kapasitesi sınırlıdır; Türkçe sürekli ön eğitim ile geliştirilmesi halinde performansının artması beklenmektedir [11].

Qwen2.5-1.5B (Alibaba Cloud, 2024): Qwen ailesinin orta-küçük segmentinde yer alır; 18 trilyon tokenle eğitilmiş, 28 dile yerleşik destek sağlayan ve Türkçe dahil pek çok dilde tatmin edici performans gösteren bir modeldir [12]. SwiGLU aktivasyonu ve Grouped-Query Attention kullanmaktadır. Bu raporda hem QLoRA hem LoRA-bf16 ince ayar yapılandırmaları için ana çatı modeli olarak seçilmiştir.

Gemma-4-E2B (Google DeepMind, 2024): Gemma 4 ailesinin 'Edge' segmentinde 2 milyar efektif parametre barındıran bir modeldir. Mixture-of-Experts (MoE) benzeri uzman seçimi mekanizmaları aracılığıyla iletim sırasında yalnızca aktif parametrelerin bir alt kümesini kullanır; bu sayede 5,1 milyar toplam ağırlığa rağmen ortalama 2 milyar etkin parametreyle çıkarım yapar. Apache 2.0 lisanslı, multimodal ve edge optimize bir modeldir [13]. Çalışmamızda yalnızca metin modu kullanılmıştır.

2.5. Parametre Verimli İnce Ayar

Tam ince ayar (full fine-tuning), büyük dil modellerinin tüm ağırlıklarını günceller ve buna bağlı olarak hem belleksel maliyet (GPU başına >40 GB VRAM gibi) hem de hesaplama maliyeti açısından tüketici donanımıyla uyumsuzdur. Bu nedenle son yıllarda parametre verimli ince ayar (PEFT) yöntemleri geliştirilmiştir.

LoRA (Low-Rank Adaptation, Hu et al., 2021) [14], önceden eğitilmiş ağırlık matrislerinin yanına düşük rütbeli (rank r) bir fark ekler ve eğitim sırasında yalnızca bu farkı günceller. Tipik olarak $r \in \{8, 16, 32, 64\}$ aralığında olup ana ağırlık matrislerinin %0,1–1,5'i kadar öğrenilebilir parametre üretir.

QLoRA (Dettmers et al., 2023) [15], LoRA'yı 4-bit nicelendirme ile birleştirerek base modeli 16-bit yerine 4-bit normal float (NF4) gösteriminde RAM'e yükler. Bu sayede tüketici GPU'larında 1,5–7 milyar parametrelili modellerin ince ayarına olanak tanımaktadır. paged_adamw_8bit optimizatörü, bellek baskısını daha da hafifletir.

Bu çalışmada her iki yöntem de uygulanmış; 12 GB VRAM'in Qwen2.5-1.5B için yeterli olduğu durumda bf16 LoRA tercih edilmiştir. Sayısal sonuçlar bu kararı doğrular niteliktedir (Bölüm 5.1).

2.6. Sınıf Dengesizliği Müdahaleleri

Tıbbi sınıflandırma görevlerinde acil sınıf (Kırmızı) genellikle veri kümesinin %1-5'lik bir diliminde yer almaktadır. Bu durum, standart cross-entropy kayıp fonksiyonu altında modelin çoğunluk sınıfı çökmesine neden olur. Literatürde bu probleme yönelik dört ana yaklaşım tartışılmaktadır [16, 17]:

- Veri seviyesinde müdahaleler: Azınlık sınıfı oversample, çoğunluk sınıfı downsample, sentetik örnek üretimi (SMOTE, ADASYN, geri çeviri ile augmentation).
- Kayıp seviyesinde müdahaleler: Sınıf ağırlıklı CE, focal loss (Lin et al., 2017), label smoothing.
- Mimari seviyesinde müdahaleler: Çift aşamalı (binary önce, çoklu sınıf sonra) sınıflandırma, uzman karışımı.
- Karar seviyesinde müdahaleler: Sınıflandırma eşiklerinin Bayes karar teorisine göre yeniden ayarlanması.

Bu çalışmada uygulanan müdahale yöntemi, veri seviyesinde temiz oversampling olmuştur (mevcut Kırmızı örneklerinin etiket gürültüsü taşımayan kopyaları). Kayıp seviyesinde müdahaleler ileride değerlendirilecek geliştirme noktaları arasında sıralanmıştır.

2.7. Cascade ve Hiyerarşik Çıkarım

Cascade veya kademeli çıkarım, küçük ve hızlı modellerin kolay örnekleri çözmesine, zor örneklerin büyük ve daha pahalı modellere yönlendirilmesine olanak tanıyan bir tasarım örüntüsüdür. Liu ve arkadaşları (2024) [18] LLM cascade'lerinde toplam maliyetin tek bir büyük modele göre %40-70 düşürülebileceğini raporlamaktadır. Mixture-of-Experts (Shazeer et al., 2017) [19] mimarileri ise bu yaklaşımın tekil bir modelin içine yerleştirilmiş hâlidir.

Bu çalışmada üç katmanlı bir cascade tasarlanmış (L1: SmolLM2-360M, L2: Qwen2.5-1.5B, L3: Gemma-4-E2B); uygulanan iki farklı yapılandırmada da (v1 ve format-düzeltilmeli v2) tek modele göre katma değer elde edilememiştir. Bu negatif bulgu Bölüm 5.9 ve Bölüm 7'de detaylandırılmıştır.

Bu literatür taraması, çalışmanın metodolojik tercihlerinin gerekçelerini ortaya koymakta ve elde edilen sonuçların literatür bağlamında konumlandırılmasını sağlamaktadır. Sonraki bölümde kullanılan veri kümeleri, model seçimi ve ince ayar protokolü ayrıntılı biçimde açıklanmaktadır.

3. MATERYAL VE YÖNTEM

3.1. Donanım ve Yazılım Ortamı

Çalışmanın deneyleri iki farklı donanım üzerinde gerçekleştirilmiştir. İlk faz olan SSH erişimi ve veri kümesi inşası, NVIDIA DGX Spark ailesinden bir GB10 (Grace-Blackwell) düğümü üzerinde (spark-25ed, aarch64, Ubuntu 24.04, BF16/FP8 destekli) çalıştırılmıştır. DGX Spark erişiminde yaşanan iki günlük kesinti sonrası tüm proje dosyaları ev tipi bir oyuncu bilgisayarına (RTX 4070, 12 GB VRAM, Windows + WSL) taşınmış ve eğitim ile değerlendirme bu ortamda tamamlanmıştır.

Yazılım yığığında Python 3.12.3 sürümü kullanılmıştır. PyTorch 2.11.0+cu128 sürümü Ada Lovelace (compute capability 8.9) altyapısında doğrulanmıştır. Hugging Face ekosisteminden transformers 5.6.2, peft 0.19.1, trl 1.2.0, accelerate 1.13.0 ve datasets 4.8.4 sürümleri kullanılmıştır. QLoRA için bitsandbytes 0.49.2 sürümü, LoRA bf16 için ise yerel AdamW optimizatörü tercih edilmiştir. Windows ortamında TRL kütüphanesinin chat_template_utils.py modülünün cp1252 codec ile bazı şablonları yükleyemediği gözlenmiş ve PYTHONUTF8=1 ortam değişkeni ile bu sorun aşılmıştır.

3.2. Veri Setleri

Bu çalışmada üç farklı kaynaktan yararlanılmıştır:

Veri Kümesi	Kaynak	İçerik	Kullanım	Lisans	Boyut
alibayram/ doktorsitesi	Hugging Face	Hekim-hasta soru/cevap	Birincil veri	Apache 2.0	5.000 örnek
Türkçe Tıbbi Acil Triaaj	Kaggle	11.770 satır triaj- etiketli	Kural çıkarımı	Public	920 örnek
alibayram/ turkish-hospital- medical-articles	Hugging Face	Hastane bilgilendirme	Kural sözlüğü genişletmesi	CC BY 4.0	24.612 makale
TUSGPT-TR- Medical- Dataset-v1	Hugging Face	TUS soru-cevap	İncelendi, dahil edilmedi	Apache 2.0	55.465 örnek

Tablo 3.1. Veri Setlerinin Özet Bilgileri.

Birincil veri kaynağı olarak alibayram/doktorsitesi seçilmiş; toplamdaki yaklaşık 187 bin satır içinden seed=42 ile rastgele bir 5.000 satırlık altküme örneklenmiştir. Örneklem aşamasında 116 alt-uzmanlık 23 ana bölüme normalize edilmiş, en az 20 karakter eşiği uygulanmış ve 'Diğer' kategorisi elenmiştir. Hugging Face'in alibayram/turkish-hospital-medical-articles veri kümesine erişim yetkisinin gecikmesi nedeniyle bu kaynak tek başına eğitim verisine dahil edilmemiş; ancak etiketleyici sözlüğünün sağlamasında istisnai olarak yararlanılmıştır.

İkinci kaynak olan Kaggle Türkçe Tıbbi Acil Triaaj veri kümesi 920 örnek içermekte ve her örnek için urgency_label alanı bulundurmaktadır. Bu etiketler aşağıdaki şekilde Türkçe triaj kategorilerine

eşleşmiştir: NORMAL → Yeşil, ACİL → Sarı, ÇOK ACİL → Kırmızı. Veri kümesindeki frekanslar (Yeşil 309, Sarı 418, Kırmızı 193) doktorsitesi ile birleştirilen kural tabanlı etiketleyiciye anahtar kelime sözlüğü olarak dahil edilmiştir.

3.3. Etiketleme Protokolü

Doktorsitesi veri seti hekim-hasta soru-cevap çiftleri içerdiğinden ve bu çiftler ham hâlinde triaj etiketi taşımadığından; etiketleme sürecinin tamamı kural tabanlı bir sınıflandırıcı tarafından gerçekleştirilmiştir. Sınıflandırıcı `scripts/label\_data.py` dosyasında uygulanmış olup üç katmanlı bir öncelik mekanizması içermektedir:

Birinci katmanda STRONG_RED_PATTERNS olarak adlandırılan kritik faz listesi taranır. Bu listede kalp krizi, inme, ani yüzde felç, ensede sertlik, anafilaktik şok gibi 26 ifade yer almaktadır. Eşleşme bulunduğu PAST_TENSE_MARKERS filtresinden geçirilerek 'geçen yıl bir kalp krizi geçirdim' tipi geçmiş zaman ifadelerinin Kırmızı sınıfına atanması engellenir. Bu filtreden geçen örnekler doğrudan Kırmızı olarak etiketlenir.


İkinci katmanda kritik belirti listesindeki kelimelerin (Bölüm 3.3.1'de detaylandırılmıştır) akut başlangıç markerlarıyla (ani, aniden, birdenbire, çok şiddetli, acil servis, ambulans, 112) birlikte aynı cümle içerisinde geçmesi durumunda, geçmiş zaman filtresi sağlandığı sürece Kırmızı olarak etiketleme yapılır.

Üçüncü katmanda TF-IDF benzeri bir skarlama uygulanır. Her sınıf için (Yeşil, Sarı, Kırmızı) Kaggle veri setinden elde edilen ayırt edici anahtar kelimelerin ağırlık değerleri toplanır ve argmax stratejisiyle bir sınıf seçilir. Eğer skarlama belirsizliğe neden olur ve hiçbir kritik Kırmızı sinyali bulunmazsa varsayılan olarak Sarı atanır. Hafif ifade (mild_phrases) listesindeki kelimelerin sıklığı yüksekse ve baskın bir Kırmızı skor mevcut değilse Yeşil olarak etiketleme yapılır.

Bu üç katmanlı kural seti uygulandığında doktorsitesi veri kümesindeki 5.000 örneğin sonuç dağılımı Sarı 3.262 (%65,2), Yeşil 1.527 (%30,5) ve Kırmızı 211 (%4,2) şeklinde gerçekleşmiştir. Bu dağılım, Türkiye acil servislerine yapılan günlük başvurularda gerçekte gözlemlenen oranlarla büyük oranda uyumludur (gerçek Kırmızı vakalar 112 üzerinden ambulans çağırısı yapmakta ve doktorsitesi gibi web platformlarına nadiren ulaşmaktadır).

3.4. Veri Bölme Protokolü

Etiketlenmiş 5.000 örnek, ders şartnamesinde tanımlanan zorunlu protokole uygun olarak %80 / %10 / %10 oranlarıyla eğitim, doğrulama ve test alt kümelerine ayrılmıştır. Bölme işlemi tek değil iki boyutlu (triaj × bölüm) bir stratifikasyonla yapılmış; böylelikle hem triaj hem bölüm dağılımının üç alt kümede de korunması sağlanmıştır. Tohum (seed) 42 olarak sabitlenmiştir.




Şekil 2. Veri bölme sonrası triaj sınıf dağılımı. Sayılar mutlak örnek sayısını, parantez içindeki yüzdeler kümeye oranı belirtir.

Tablo 3.2'de bölmenin sayısal sonuçları sunulmaktadır.

Alt küme	Toplam	Yeşil (%)	Sarı (%)	Kırmızı (%)
Eğitim	3.972	1.211 (%30,5)	2.599 (%65,4)	162 (%4,1)
Doğrulama	475	142 (%29,9)	318 (%66,9)	15 (%3,2)
Test	553	174 (%31,5)	345 (%62,4)	34 (%6,1)
TOPLAM	5.000	1.527 (%30,5)	3.262 (%65,2)	211 (%4,2)

Tablo 3.2. Veri bölme istatistikleri (seed=42).

Şekil 4'te etiketli veri kümesindeki en yoğun 12 tıbbi bölüm gösterilmiştir.



Şekil 4. Etiketli veri setinde en yoğun 12 tıbbi bölüm.

Veri seti büyük ölçüde Kadın Doğum (1.374), Çocuk Sağlığı (513), Dahiliye (501) ve Nöroloji (492) alanlarına yoğunlaşmaktadır. Bu yoğunluk doktorsitesi platformunun kullanıcı kompozisyonuyla uyumludur; ev içi hasta soruları büyük oranda kadın sağlığı ve pediatri eksenlidir. Acil Tıp (yalnızca 5 örnek) ve Aile Hekimliği (6 örnek) sınıflarındaki düşük temsil, modelin bu bölümleri öğrenememe riskini ortaya koymaktadır; ancak bu durum uygulama senaryosuna uygundur çünkü gerçek Acil Tıp vakaları platforma soru gönderme sıklığı çok düşüktür.

3.5. Model Seçimi

Zorunlu benchmark protokolü kapsamında dört modelden en az üçünün denenmesi şart koşulmuştur. Bu çalışmada bilinçli olarak Model A, Model C ve Model D seçilmiştir; gerekçeler aşağıda açıklanmıştır:

Model	Parametre	Bağlam	Tokenizer Boyutu	Mimari
SmolLM2-360M	362 M	8 K	49.152	Llama2-vari, RoPE
Qwen2.5-1.5B	1,5 B	32 K	151.643	GQA + SwiGLU
Gemma-4-E2B	~2 B*	8 K	256.000	MoE-vari, edge optimize

Tablo 3.3. Model mimari özet bilgileri (* Gemma-4-E2B'nin toplam ağırlık sayısı 5,1 B; etkin parametre sayısı yaklaşık 2 B).

SmolLM2-360M, edge cihaz uygunluğu ve sınırlı parametre kapasitesinin Türkçe medikal görevde öğrenme tavanını test etmek üzere seçilmiştir. Qwen2.5-1.5B, çok dilli kapasitesi ve GQA mimarisi sayesinde küçük cihazda dahi düşük gecikme sunma potansiyeli ile orta segmentin ana adaydır. Gemma-4-E2B ise Google DeepMind'in en güncel açık kaynak edge modeli olarak dahil edilmiştir; MoE-

vari uzman seçim mekanizması sayesinde 2 milyar etkin parametreyle daha büyük modellere kıyasla rekabetçi bir performans hedeflemektedir.

Model B (TinyLlama-1.1B), Qwen2.5-1.5B ile aynı segmente düştüğü ve Türkçe kapasitesi belirgin olarak daha zayıf olduğu için zaman bütçesi kısıtı altında atlanmıştır.

3.6. İnce Ayar Stratejisi

Üç farklı ince ayar yapılandırması uygulanmıştır:

(i) QLoRA 4-bit nf4 — bitsandbytes ile temel ağırlıkları 4-bit normal float gösteriminde belleğe yükler; LoRA adaptörlerini bf16 hassasiyetinde günceller. SmolLM2-360M, Qwen2.5-1.5B ve Gemma-4-E2B modellerinde bu yapılandırma denenmiştir.

(ii) LoRA bf16 (no 4-bit) — temel ağırlıkları bf16 olarak yükler. 12 GB VRAM ortamında Qwen2.5-1.5B için bellek baskısı yaratmadığından tercih edilmiştir; QLoRA'ya kıyasla yaklaşık 2,5 kat hız avantajı sağlamıştır.

(iii) LoRA bf16 — Sınıf Dengesizliği Mukerrer Eğitim — Qwen2.5-1.5B üzerinde train_balanced.jsonl veri kümesiyle (Bölüm 3.9) yapılan ek bir eğitim yapılandırmasıdır.

Tablo 3.4 her modelin ince ayar hiperparametrelerini özetlemektedir.

Model	Quant	LoRA r/ α	bs/ga	Epoch	max_len	lr	Süre
SmolLM2-360M	QLoRA 4-bit	16/32	8/2	3	768	3e-4	62,3 dk
Qwen2.5-1.5B QLoRA	QLoRA 4-bit	16/32	4/4	2	896	2e-4	89,2 dk
Qwen2.5-1.5B LoRA bf16	—	16/32	2/8	2	896	2e-4	35,6 dk
Qwen2.5-1.5B BALANCED	—	16/32	2/8	2	896	2e-4	~36 dk
Gemma-4-E2B	QLoRA 4-bit	8/16	1/16	1	512	1e-4	42,8 dk

Tablo 3.4. İnce ayar hiperparametreleri.

3.7. Prompt Şablonu

Tüm modeller eğitim ve değerlendirme aşamalarında tek-tek tutarlı bir üç alanlı şablon kullanılmıştır:

Görev

Aşağıdaki hasta semptom metnini analiz et. Triaaj seviyesini (Yeşil/Sarı/Kırmızı) ve en uygun tıbbi bölümü belirle. Cevabını SADECE geçerli bir JSON objesi olarak ver.

Semptom

<hasta metni>

Cevap

```
{"triaj": "...", "bolum": "...", "neden": "..."}"
```

JSON çıktının `triaj`, `bolum` ve `neden` alanlarını içermesi sözleşmeli olarak şart koşulmuştur. Modelin yapılandırılmış çıktıyı doğru üretip üretmediği, parse_ok bayrağı ile izlenmiştir; geçersiz JSON üreten örnekler accuracy hesaplarında 'belirsiz' olarak ele alınmıştır.

Tüm sistem çıktısı, etik bir önlem olarak doktor onayı zorunluluğunu vurgulayan bir feragat metniyle ("Bu sistem sadece bir ön yönlendirme aracıdır, tıbbi tanı koymaz. Acil durumlarda 112'yi arayın.") birlikte sunulmuştur.

3.8. Değerlendirme Metrikleri

Sınıflandırma performansı için standart üç metrik kullanılmıştır:

- Accuracy: Doğru tahmin edilen örnek oranı.
- Macro-F1: Üç sınıf için F1 değerinin aritmetik ortalaması; sınıf dengesizliğinde adil bir değerlendirme sağlar.
- Weighted-F1: Her sınıf F1 değerinin örnek sayısı ağırlıklı ortalaması.

Klinik güvenlik açısından iki ek metrik raporlanmıştır:

- False Green Rate (FGR): Gerçekte Sarı veya Kırmızı olan ancak Yeşil tahmin edilen örnek oranı. FGR > 0 değeri klinik açıdan kabul edilemez bir uygulama riskini gösterir.
- False Negative Rate – Red (FNR-Red): Gerçek Kırmızı vakaların Kırmızı olarak tahmin edilemediği oran (1 – Kırmızı recall). Literatürde klinik güvenlik için <5–10 hedeflenir.

Sistem performansı için inference gecikmesi (avg, p50, p95 ms), JSON parse başarı oranı, peak GPU bellek kullanımı (MB) ve adapter disk boyutu (MB) raporlanmıştır.


3.9. Sınıf Dengesizliği Müdahalesi

Eğitim seti dağılımında Kırmızı sınıfının yalnızca %4,1 oranında olması, ilk dört ince ayarın tamamının Sarı sınıfa çökmesine neden olmuştur. Bu durumun ele alınması için iki bağımsız müdahale stratejisi denenmiştir.

Birinci stratejide kural tabanlı etiketleyicinin Kırmızı eşik değerleri gevşetilmiş (STRONG_RED_PATTERNS genişletildi, MEDIUM seviye eklendi, skor eşikleri 15→10 arasına çekildi). 5.000 örnek yeniden etiketlendiğinde Kırmızı sayısı 421'e yükseldi; ancak `scripts/spotcheck\_kirmizi.py` ile 30 rastgele örnek üzerinde yapılan manuel doğrulamada yanlış pozitif (FP) oranının %50'nin üzerinde olduğu tespit edilmiştir. 'inme' regex ifadesinin 'inmemiş' kelimesini yakalaması, geçmiş zaman filtresinin atlanması ve hipotetik mention'ların yakalanması başlıca FP kaynaklarıdır. Bu strateji, kirli etiketlerin sinyal kalitesini bozma riski göz önünde bulundurularak terk edilmiş ve etiketleyici orijinal hâline döndürülmüştür.

İkinci stratejide ise mevcut 162 Kırmızı örneğin 4 kez kopyalanmasıyla `train\_balanced.jsonl` veri kümesi oluşturulmuştur (`scripts/balance\_train.py`). Bu sayede Kırmızı oranı %4,1'den %14,5'e yükselmiş; toplam eğitim seti boyutu 4.458'e çıkmıştır. Test ve doğrulama setlerine müdahale edilmemiş, etiket kalitesi

mevcut Kırmızı örnekler içinde korunmuş ve seed=42 ile tekrarlanabilirlik sağlanmıştır. Şekil 3 bu müdahaleyi görselleştirmektedir.



Şekil 3. Sınıf dengesizliği: orijinal eğitim, oversample edilmiş eğitim ve test seti karşılaştırması. Yatay kesikli çizgi optimal denge eşliğini (%33) göstermektedir.

4. DENEYSEL DÜZEN

Çalışma dokuz ayrı değerlendirme yapılandırması içermektedir:

#	Yapılandırma	Açıklama
1	SmolLM2-360M Zero-shot	Önceden eğitilmiş model, görev özel ince ayar yok.
2	Qwen2.5-1.5B Zero-shot	Önceden eğitilmiş model.
3	Gemma-4-E2B Zero-shot	Önceden eğitilmiş model.
4	SmolLM2-360M FT (QLoRA)	QLoRA r=16, 3 epoch.
5	Qwen2.5-1.5B FT (QLoRA)	QLoRA r=16, 2 epoch.
6	Qwen2.5-1.5B FT (LoRA bf16)	LoRA bf16 r=16, 2 epoch.
7	Gemma-4-E2B FT (QLoRA)	QLoRA r=8, 1 epoch.
8	Qwen2.5-1.5B BALANCED	Kırmızı 4× oversample veriyle yeniden eğitildi.
9	Cascade v1 ve v2	L1→L2→L3 mimarisi (iki yapılandırma).

Tablo 4.1. Değerlendirme yapılandırmaları.

Cascade mimarisi şu mantıkla çalışmaktadır: Kullanıcının semptom metni önce SmolLM2 (L1) tarafından değerlendirilir; eğer model çıkarımı 'Yeşil' ise süreç tamamlanır. Aksi durumda Qwen2.5-1.5B (L2) devreye girer ve eğer 'Yeşil' kararı verirse süreç tamamlanır. L2 de 'Yeşil' kararı vermez ise Gemma-4-E2B (L3) son kararı verir. Bu tasarımın hedefi düşük öncelikli vakaların hızlı modeller tarafından erken sonlandırılması, karmaşık vakaların ise daha güçlü modele yönlendirilmesi ve toplam ortalama gecikmenin minimize edilmesidir.

Cascade v2, v1'den iki noktada farklılaşmaktadır: (i) Gemma-4-E2B `train\_balanced.jsonl` ile yeniden eğitilmiştir (1 epoch, ~25 dk); (ii) cascade promptundaki üçüncü `### Ön-Analiz` alanı kaldırılarak prompt formatı L3'ün eğitim formatıyla birebir uyumlu hâle getirilmiştir. Bu iki değişikliğin amacı, v1'de gözlemlenen 'cascade tek modele eşit' bulgusunun bir prompt format uyumsuzluğundan kaynaklanıp kaynaklanmadığını test etmektir.

Tüm yapılandırmalar aynı 553 örneklik test kümesi üzerinde değerlendirilmiş; bu test kümesi müdahalelerden bağımsız tutulmuştur. Latency ölçümleri RTX 4070 GPU'sunda yapılmıştır.

5. SONUÇLAR


5.1. Eğitim Süreç Metrikleri

Tablo 5.1, beş ince ayar yapılandırmasının eğitim sırasındaki temel metriklerini özetlemektedir.

Yapılandırma	Süre (dk)	eval_loss	Token acc	Trainable %	Adapter (MB)
SmolLM2-360M QLoRA	62,3	1,625	0,664	1,18 %	21,0
Qwen2.5-1.5B QLoRA	89,2	1,662	0,681	1,18 %	48,4
Qwen2.5-1.5B LoRA bf16	35,6	1,615	0,684	1,18 %	85,3
Qwen2.5-1.5B BALANCED	~36	1,617	0,683	1,18 %	85,3
Gemma-4-E2B QLoRA	42,8	1,460	0,701	0,52 %	70,3


Tablo 5.1. Eğitim süreç metrikleri.

Şekil 5'te beş yapılandırmanın eğitim kayıpları çizilmiştir. Tüm modellerde kayıp eğrileri stabil bir düşüş gösterirken, Gemma-4-E2B en düşük kayıp değerini (1,460) elde etmiş ve eğitim tabanını farklılaştırmıştır.



Şekil 5. Modellerin eğitim sırasında kayıp (loss) eğrileri.

Şekil 6, final eval_loss değerlerinin yan yana karşılaştırılmasını sunmaktadır. Eval kaybı açısından sıralama Gemma-4 (1,460) < Qwen LoRA bf16 (1,615) ≤ Qwen BALANCED (1,617) < SmolLM2 (1,625) < Qwen QLoRA (1,662) şeklindedir. QLoRA ve LoRA bf16 arasındaki 47 puanlık fark, bf16 yapılandırmasının daha yüksek hassasiyetli optimizasyon gradyanı sunmasıyla açıklanabilmektedir.



Şekil 6. Modellerin final eval_loss karşılaştırması.


5.2. Zero-shot Baseline

Üç temel modelin görev özel ince ayar uygulanmadan önceki performansı, fine-tuning ile elde edilen kazanımı sayısallaştırmak için raporlanmıştır.

Model	parse_ok	Acc	F1-macro	F1-w	FGR	FNR-Red	BÖL acc
SmolLM2-360M zero-shot	%2,7	0,000	0,000	0,000	0,000	1,000	0,000
Qwen2.5-1.5B zero-shot	%80,8	0,000	0,000	0,000	0,000	1,000	0,000
Gemma-4-E2B zero-shot	%56,4	0,139	0,118	0,204	0,000	0,971	0,029

Tablo 5.2. Zero-shot triaj sonuçları (n=553).

SmolLM2-360M, JSON şemasını üretme kapasitesi açısından son derece sınırlı bir performans göstermiştir (parse_ok %2,7); buna karşın Qwen2.5-1.5B ham JSON yapısını başarıyla üretmiş (parse_ok %80,8) ancak alan değerlerini Türkçe triaj kategorileriyle eşleştirememiştir (acc 0). Gemma-4-E2B, parse oranı %56,4 ile orta seviyede kalırken triaj doğruluğu 0,139'a ulaşmıştır; bu marjinal başarı modelin önceden eğitiminde Türkçe medikal metnin daha yoğun temsil edilmiş olabileceğine işaret etmektedir. Ancak bu değer de klinik kullanım için kabul edilebilir olmadığı açıktır.



Şekil 7. Zero-shot ve fine-tuned triağ performansı karşılaştırması.

Şekil 7, fine-tuning müdahalesinin Macro-F1'de yaklaşık iki katlık ve doğrulukta dört kata yakın bir artış sağladığını görsel olarak ortaya koymaktadır. Bu sonuç, küçük dil modellerinin Türkçe medikal görevde önceden eğitim aşamasında tek başına yetersiz olduğunu doğrulamaktadır.

5.3. Fine-tuned Performans

Tablo 5.3'te dört temel ince ayar ile dengeli ince ayar yapılandırmalarının triağ ve bölüm performansları sunulmuştur.


Model	parse_ok	Acc	F1-m	F1-w	FGR	FNR-Red	BÖL acc	BÖL F1-m
SmolLM2 FT (QLoRA)	%91,5	0,562	0,244	0,456	0,000	1,000	0,103	0,023
Qwen2.5 FT (QLoRA)	%99,8	0,622	0,260	0,483	0,000	1,000	0,609	0,351
Qwen2.5 FT (LoRA bf16)	%100	0,624	0,256	0,479	0,000	1,000	0,628	0,406
Gemma-4 FT (QLoRA)	%100	0,624	0,256	0,479	0,000	1,000	0,638	0,402
Qwen2.5 BALANCE D	%100	0,618	0,390	0,502	0,000	0,529	0,637	0,423

Tablo 5.3. Fine-tuned triağ ve bölüm sonuçları (n=553 test).

Beklenmedik bir bulgu olarak ilk dört fine-tuned yapılandırma, doğruluk değerinde adeta aynı yere yakınsamıştır: 0,562 (SmolLM2) ile 0,624 (Gemma) arasında. Bu değerlerin tümü test kümesindeki Sarı sınıfının oranıyla ($345/553 = 0,624$) örtüşmektedir. FNR-Red değerlerinin 1,000 olması modellerin hiçbir Kırmızı vakayı yakalayamadığını gösterirken; FGR'nin 0,000 olması bu modellerin tehlikeli yönde hata yapmadığını da kanıtlamaktadır.

Buna karşın bölüm yönlendirme performansları sağlıklı bir farklılaşma göstermiştir: SmolLM2-360M yalnızca %10,3 BÖLÜM doğruluğunda kalmış (küçük kapasite ve 23 sınıflı bölüm dağılımının yarattığı tavan), Qwen2.5-1.5B QLoRA %60,9, Qwen2.5-1.5B LoRA bf16 %62,8 ve Gemma-4-E2B %63,8 değerine ulaşmıştır. Bu değerler küçük dil modellerinin metinden bölüm çıkarımının modellenemediğini göstermekte; yapılandırılmış sınıflandırma görevi olarak triajın ise doğal olarak daha zor olduğunu doğrulamaktadır.

Dengeli yapılandırma ile Qwen2.5-1.5B'nin Macro-F1 değerinde 0,256'dan 0,390'a (+%52 görelî) bir iyileşme gözlemlenmiştir. Bu iyileşme açıklamasıyla birlikte Bölüm 5.6'da ayrıntılı olarak ele alınmaktadır.




Şekil 8. Tüm değerlendirme yapılandırmalarında Macro-F1 karşılaştırması.

5.4. Confusion Matrix Analizi

Şekil 9, dokuz farklı yapılandırmanın confusion matrix'lerini bir araya getirmektedir. Beklenildiği üzere zero-shot satırlarında modellerin büyük çoğunluğu 'Diğer' (yani parse edilemeyen veya etiket dışı) kategorisine düşmüştür. Fine-tuned satırlarında SmolLM2-360M, Qwen2.5-1.5B (QLoRA, LoRA bf16) ve Gemma-4-E2B'nin tamamı Sarı sütununa yığılmış olup, Kırmızı tahmin yapamamıştır.

Şekil 9. 9 Çalışmaya ait Confusion Matrix Karsilastirmasi (n=553 test)




Şekil 9. Dokuz değerlendirme yapılandırmasına ait confusion matrix karşılaştırması.

En anlamlı değişiklik, Qwen2.5 BALANCED ve Cascade v2 satırlarında görülmektedir. Qwen2.5 BALANCED 34 Kırmızı vakanın 16'sını doğru şekilde Kırmızı olarak tahmin etmiştir ($16/34 = 0,471$ recall). Buna karşın 19 Sarı vaka yanlışlıkla Kırmızı olarak işaretlenmiş; bu durum FNR-Red düşüşüyle birlikte ortaya çıkan bir trade-off'tur.

5.5. Sınıf Bazlı Performans

Şekil 10, beş fine-tuned yapılandırmanın sınıf bazlı F1 değerlerini göstermektedir.



Şekil 10. Sınıf bazlı F1 skoru (Yeşil/Sarı/Kırmızı).

Tüm yapılandırmalarda Yeşil sınıfının F1 değeri sıfırdır. Bu, çalışmanın en açık negatif bulgusudur ve Bölüm 6'da ayrıntılı olarak tartışılacaktır. Sarı sınıfının F1 değeri 0,73–0,77 aralığında bulunmakta ve dengeli yapılandırmada hafifçe gerilemektedir (bu beklenen bir trade-offtur, çünkü Sarı recall değeri %100'den %94,5'e düşmüştür). Kırmızı sınıfı F1 değeri yalnızca Qwen2.5 BALANCED ve Cascade v2 yapılandırmalarında sıfırdan farklıdır (~0,40). Bu durum, müdahalenin Kırmızı sınıfını öğrenebilir hâle getirdiğini ancak henüz klinik açıdan yeterli olmadığını göstermektedir.

5.6. Sınıf Dengesizliği Müdahalesi Etkisi

Tablo 5.4, müdahaleden önceki ve sonraki sayısal göstergeleri yan yana sunmaktadır.

Metrik	Önceki (LoRA bf16)	Sonraki (BALANCED)	Δ
Accuracy	0,624	0,618	-0,006
Macro-F1	0,256	0,390	+0,134 (+%52 görelî)
Weighted-F1	0,479	0,502	+0,023
FGR	0,000	0,000	korundu
FNR-Red	1,000	0,529	-0,471 (mutlak)
BÖLÜM accuracy	0,628	0,637	+0,009
Inference latency	1.463 ms	1.407 ms	-56 ms


Tablo 5.4. Sınıf dengesizliği müdahalesi karşılaştırması (Qwen2.5-1.5B).

Trade-off net bir biçimde gözlemlenmektedir: doğruluk değerinde 0,6 puanlık marjinal bir düşüş yaşanırken (Sarı recall'unun %100'den %94,5'e gerilemesinden kaynaklı), Macro-F1 değeri %52 oranında artış göstermiştir. Daha kritik olarak, FNR-Red 0,471 mutlak değerde düşmüştür; bu değer 34 Kırmızı vakanın 16'sının (önceden 0) yakalanabildiği anlamına gelmektedir. FGR'nin korunması (0,000) ise önemli

bir güvenlik bulgusudur; modelin Sarı veya Kırmızı vakaları tehlikeli yönde Yeşil olarak tahmin etmediği teyit edilmiştir.


Bu radar şeması müdahalenin etkisini farklı boyutlarda görselleştirmektedir.

Sekil 11. Sınıf Dengesizliği Müdahalesi Etkisi (Qwen2.5-1.5B)



Şekil 11. Sınıf dengesizliği müdahalesi radar karşılaştırması (Qwen2.5-1.5B).

Şekil 17 ise Kırmızı sınıfının yakalanması özelinde hangi alt metriklerin değiştiğini ayrıştırmaktadır.




Şekil 17. Sınıf dengesizliği müdahalesi: Kırmızı sınıfı yakalama etkisi.

Klinik hedef olarak literatürde kabul gören Kırmızı recall $\geq$ %90 değeri (Şekil 17'de yatay kesikli çizgi) henüz karşılanmamıştır. Mevcut %47,1 değer, müdahalenin tek başına yeterli olmadığını ve loss seviyesinde ek müdahaleler (focal loss, ağırlıklandırılmış CE) gerektiğini göstermektedir.

5.7. Pareto Analizi

Şekil 12, parametre sayısı ile Macro-F1 arasındaki ilişkiyi göstermektedir. Adapter MB büyüklükleri kabarcık çapı ile temsil edilmiştir.




Şekil 12. Pareto eğrisi: Model boyutu vs Macro-F1 (kabarcık büyüklüğü = adapter MB).

Pareto frontier, SmolLM2-360M (0,36 B parametre, F1m=0,244) ve Qwen2.5-1.5B BALANCED (1,5 B, F1m=0,390) noktaları arasında uzanmaktadır. Gemma-4-E2B, daha büyük olmasına rağmen frontier üzerinde değildir; bu durum yalnızca 1 epoch eğitim almasıyla açıklanabilir.

5.8. Gecikme - Performans Dengesi


Şekil 13, ortalama inference gecikmesinin (ms, log ölçek) doğruluk değeriyle ilişkisini göstermektedir.



Şekil 13. Gecikme - performans dengesi (n=553).

Qwen2.5-1.5B BALANCED, 1.407 ms ortalama gecikme ile en uygun maliyet-performans noktasında konumlanmaktadır. Cascade v2'nin 10.752 ms gecikmesi ise tek modele kıyasla yaklaşık 7,6 katlık bir maliyet artışına karşılık aynı doğruluğu (0,618) sunmaktadır.

JSON parse başarı oranı açısından Şekil 14, fine-tuned modellerin bu konuda yeterli düzeye ulaştığını göstermektedir.



Şekil 14. JSON parse başarı oranı.

5.9. Cascade Çıkarım Sonuçları

Tablo 5.5, cascade v1 ve v2 yapılandırmalarının sonuçlarını tek model Qwen-balanced ile karşılaştırmaktadır.

Yapilandirma	Acc	F1-m	FNR-Red	FGR	Latency avg	Latency p95
Qwen2.5-1.5B BALANCED (tek)	0,6184	0,3898	0,529	0,000	1.407 ms	1.516 ms
Cascade v1 (L1+L2- bal+L3)	0,6184	0,3898	0,529	0,000	15.498 ms	26.535 ms
Cascade v2 (format düzeltme)	0,6184	0,3884	0,529	0,000	10.752 ms	15.768 ms


Tablo 5.5. Cascade v1 ve v2 sonuçları (n=553).

Cascade v1 yapılandırması, tek model Qwen-balanced ile bit-be-bit aynı tahminleri üretmiştir (553/553 örnekte aynı). Bu sonuç başlangıçta bir hata gibi değerlendirilse de, beklenmedik bir bulgu olarak kalmıştır.

Cascade v2'de Gemma-4-E2B yeniden eğitilmiş ve cascade promptundaki üçüncü `### Ön-Analiz` alanı kaldırılarak prompt formatı L3 eğitim verisiyle uyumlu hâle getirilmiştir. Bu müdahale sonrasında yapılan tam değerlendirmede 553 örnekten yalnızca 1 tanesinde tahmin farklılığı görülmüştür (idx 302: gerçek=Yeşil, Qwen=Sarı, Cascade v2=Kırmızı, yani tek bir aşırı eskalasyon hatası). Bu tek farklılık istatistiksel olarak anlamsızdır ve cascade'in tek modele üstünlük sağlayamadığını kanıtlamaktadır.

Şekil 16, cascade v1 ve v2'de katmanlar arası dağılımı göstermektedir. Her iki yapılandırmada da örneklerin %100'ü L3 katmanına eskale olmuştur; bu durum L1 ve L2 'Yeşil' kararı vermediği için cascade'in tasarlanan erken durdurma davranışının çalışmadığını işaret etmektedir.

Şekil 16. Cascade Mimarisinde Katman Dağılımı




Şekil 16. Cascade mimarisinde katman dağılımı.

Cascade'in mevcut formdaki başarısızlığı, üç olası nedene dayandırılmaktadır: (i) L1 ve L2 modellerinin kendileri Yeşil sınıfını öğrenememiş ve dolayısıyla erken sonlandırma için temel girdi olamamışlardır; (ii) Gemma-4-E2B'nin 1 epoch QLoRA ince ayarı ile elde edilen kapasitesi, cascade promptunda gördüğü önceki katman çıkarımını yansıtacak (echo) düzeyde olabilir; (iii) cascade için ihtiyaç duyulan güven (confidence) hesabı standart logit çıktılarından elde edilmek yerine tek başına etiket düzeyinde yapılmıştır, bu da düşük güvenli kararların doğru yönlendirilmesini engellemiş olabilir. Gelecek çalışmada bu üç problem için ayrı ayrı müdahale yöntemleri geliştirilebilir.

5.10. Kaynak Tüketimi

Şekil 15, beş ince ayar yapılandırmasının eğitim süresini, peak GPU bellek tüketimini ve adapter disk boyutunu üç ayrı panelde sunmaktadır.

Şekil 15. Eğitim ve Inference Asamasında Kaynak Tüketimi



Şekil 15. Eğitim ve inference aşamasında kaynak tüketimi.

Peak VRAM açısından SmolLM2 (0,87 GB) en hafif modeldir ve düşük donanımlı sistemlerde çalışabilir. Qwen2.5-1.5B üç farklı yapılandırmasıyla 3,28 GB tepe değer göstermiş; tek bir GPU'da çoklu modelin yan yana çalıştırılmasına olanak tanımıştır. Gemma-4-E2B 10,42 GB peak değer ile 12 GB VRAM sınırına yakın bir profil çizmektedir; daha küçük donanımlarda çalıştırılabilirliği için 4-bit nicelendirme ön koşuldur.

Eğitim süresi açısından dikkat çekici bulgu Qwen LoRA bf16 (35,6 dk) ile Qwen QLoRA (89,2 dk) arasındaki yaklaşık 2,5 katlık hızdır. Bu fark, RTX 4070'in 12 GB VRAM kapasitesinin 1,5 milyar parametrelili Qwen modelini bf16 yüklemeye yeterli olmasından kaynaklanmaktadır; QLoRA'nın 4-bit dönüştürme + dequantize ek hesaplama yükü gereksiz ek maliyet üretmiştir.

5.11. Standart Sonuç Tablosu (Benchmark Protokolü)

Aşağıda ders kapsamında belirlenen standart sonuç tablosu protokole uygun şekilde doldurulmuştur. Tablo 5.6, ortak benchmark makalesine doğrudan kaynak oluşturmaktadır.

Model	Param.	FT Yöntemi	Acc	Macro-F1	Eğitim	Inference (ms)	Boyut (MB)
SmolLM2-360M	362 M	QLoRA r=16	0,562	0,244	62,3 dk	1.706	21,0 (adapter)
Qwen2.5-1.5B	1,5 B	QLoRA r=16	0,622	0,260	89,2 dk	1.391	48,4 (adapter)
Qwen2.5-1.5B	1,5 B	LoRA bf16 r=16	0,624	0,256	35,6 dk	1.463	85,3 (adapter)
Gemma-4-E2B	~2 B	QLoRA r=8	0,624	0,256	42,8 dk	2.733	70,3 (adapter)
Qwen2.5-1.5B BAL.	1,5 B	LoRA bf16 r=16	0,618	0,390	~36 dk	1.407	85,3 (adapter)


Tablo 5.6. Standart sonuç tablosu (benchmark protokolüne uygun).

6. HATA ANALİZİ

Bu bölümde Qwen2.5-1.5B BALANCED modelinin yanlış tahminleri sistematik olarak analiz edilmiştir. Test kümesindeki 553 örnekten 211 tanesinde tahmin gerçekten farklılaşmıştır (accuracy 0,618 üzerinden hesap).

6.1. Hata Taksonomisi

Şekil 18, hataların gerçek sınıfa ve tahmin edilen sınıfa göre dağılımını sunmaktadır.



Şekil 18. Hata taksonomisi (Qwen2.5 BALANCED modeli üzerinden).

Hata paterni baskın olarak iki kategoride yoğunlaşmaktadır: (i) Yeşil → Sarı (164 örnek, %77,7) modelin Yeşil sınıfı öğrenememesi sonucu yaşanan yumuşak yüksek tahmin; (ii) Sarı → Kırmızı (19 örnek, %9,0) ve Yeşil → Kırmızı (10 örnek, %4,7) yumuşak eskalasyon hataları. Klinik açıdan en tehlikeli kategori olan Kırmızı → Sarı durumunda 18 örnek bulunmakta; bu durum 34 Kırmızı vakanın yarısından fazlasının atlandığını göstermektedir (FNR-Red = 0,529).

6.2. Vaka 1 — Kırmızı'nın Sarı Olarak Atanması (Tehlikeli Atlama)

Aşağıdaki örnek, model tarafından Kırmızı yerine Sarı olarak değerlendirilen bir vakadır:

Hasta metni (idx=3): "Suphi bey meraba çok küçükken biri zorla parmakla bozmuştu o an anlamadım bile bozulup bozmadını kan geldim hatırlamıyodum ama içimde kustu seneler sonra doktora gittimde öğrendimki bes yonunde bozulmuş..."

Gerçek triaj: Kırmızı | Tahmin: Sarı | Gerçek bölüm: Kadın Doğum | Tahmin bölüm: Kadın Doğum

Analiz: Bu vaka geçmişte yaşanmış bir cinsel istismar deneyimine ait olduğundan, modelin geçmiş zaman markerlarını tetiklediği ve PAST_TENSE filtresinin Kırmızı sınıfı için kritik bir özelliği maskeleyiği görülmektedir. Kural tabanlı etiketleyicide bu vaka travma sonrası psikiyatrik veya jinekolojik aciliyet potansiyeli üzerinden Kırmızı olarak işaretlenmiş ancak model bu nüansı öğrenememiştir. Doktor doğrulamalı etiketleme aşaması bu tip vakaların etiket kalitesini iyileştirebilir.

6.3. Vaka 2 — Yeşil'in Sarı Olarak Atanması (Yumuşak Yüksek Tahmin)

Hasta metni (idx=12): "merhabalar ben gluten hastasıyım yaklaşık olarak bunu 5 ay önce öğrendim. tamamıyla unlu şeylerden uzak durmam söylendi ama ben arada bir kaçamak yapıyorum. bu bana ciddi bir rahatsızlık olarak dönermi?"

Gerçek triaj: Yeşil | Tahmin: Sarı | Bölüm: Dahiliye → Dahiliye (doğru)

Analiz: Bu örnek, kronik bir hastalıkla yaşayan ve genel danışma niteliğinde bir soru soran tipik Yeşil bir vakadır. Ancak modelin ön eğitim aşamasındaki Türkçe medikal metin tabanı, her hasta sorusunu varsayılan olarak Sarı'ya konumlandırma eğilimi geliştirmiştir. Yeşil sınıfının dilsel sinyalinin Sarı'dan ayırt edilebilir olmadığı durumlarda model Sarı'yı tercih etmektedir.

6.4. Vaka 3 — Yeşil'in Kırmızı Olarak Atanması (Aşırı Eskalasyon)

Hasta metni (idx=302, cascade v2'de farklılaşan tek örnek): Gerçek triaj: Yeşil | Qwen tek model: Sarı | Cascade v2: Kırmızı

Analiz: Cascade v2 yapılandırmasında Gemma katmanının önceki triaj kararını izlemek yerine agresif bir Kırmızı tahmini yaptığı tek örnektir. Bu vaka, cascade'in over-escalation eğilimine girebilme riskini örneklendirmektedir. Tek başına klinik açıdan tehlikeli olmasa da; FGR'nin korunmuş olması (0,000) yan etkilerden zarar verici yönde sapma olmadığını teyit etmektedir.

6.5. Vaka 4 — Bölüm Hatası: Çoklu Bölüm Karışıklığı

Hasta metni (idx=10): "Mrb Doktor Bey, ben 22 yaşındayım. bir hafta önce sol göğsümün sağ göğsüme göre büyük olduğunu ve sarktığını farkettim... sol koltuk altımda da 1 ay önce yumru çıkmıştı..."

Gerçek triaj: Kırmızı | Tahmin: Sarı | Gerçek bölüm: Genel Cerrahi | Tahmin bölüm: Ortopedi

Analiz: Bu vakada hem triaj hem de bölüm tahmininde hata yapılmıştır. Memede asimetri ve koltuk altında yumru bulgusu klinik açıdan meme malignite şüphesi taşır ve Genel Cerrahi yönlendirmesi yapılması beklenir. Modelin Ortopedi tahmini, koltuk altı bölge tanımının kas-iskelet sistemi ile karıştırılmasından kaynaklanmaktadır. Bu hata tipi, bölüm sınıfları arasındaki anatomik yakınlığın temsilini geliştiren ek özellik mühendisliği veya gözetimli bölüm sözlüğü eklemesi ile düzeltilebilir.

6.6. Vaka 5 — Doğru Tahmin Edilen Kritik Vaka

Hasta metni (idx=15): "... 6 aydır devam eden bir solunum güçlüğü sıkıntım var. İlk defa 6 ay önce öksürme sırasında sol kalbimin olduğu yere bıçak sokulmuşçasına kramp girdi..."

Gerçek triaj: Kırmızı | Tahmin: Kırmızı | Gerçek bölüm: Göğüs Hastalıkları | Tahmin bölüm: Kardiyoloji

Analiz: Bu örnek, modelin Kırmızı sınıfını başarıyla yakaladığı bir vakadır. Triaj kararı doğrudur; bölüm tahmininde Kardiyoloji önerilse de hasta metninde 'kalbimin olduğu yere kramp' ifadesi kardiyolojik şüpheyi haklı kılmaktadır. Bu öneri klinik açıdan uygun bir farklı tanı stratejisidir; gerçek bölüm Göğüs Hastalıkları olsa da Kardiyoloji yönlendirmesi tehlikeli bir yönlendirme değildir.

6.7. Yeşil Sınıfının %0 Recall Sorunu

Çalışmada en çarpıcı negatif bulgulardan biri, dokuz yapılandırmanın hiçbirinde Yeşil sınıfının F1 değerinin sıfırdan farklı olmamasıdır. Test kümesinde 174 Yeşil örnek bulunmasına rağmen hiçbirini doğru olarak tahmin edilememiştir. Bu sorunun üç olası nedeni bulunmaktadır:

Birincisi, dilsel örtüşme. Yeşil ve Sarı sınıfları arasındaki sınır, semptom dilinde belirgin değildir. 'Baş ağrısı', 'halsizlik', 'uyku düzensizliği' gibi ifadeler hem Yeşil hem Sarı etiketli örneklerde sıkça yer almaktadır. Modelin bu örtüşmeyi ayırt etmesi için ek bir ayırt edici özellik yakalaması gerekirken; mevcut veride bu sinyal zayıftır.

İkincisi, etiket gürültüsü. Kural tabanlı etiketleyicinin Yeşil-Sarı sınırında varsayılan olarak Sarı'ya kaydırma yaptığı (default = Sarı) bilinmektedir. Bu durum Yeşil etiketinin gerçek frekansının altında kalmasına ve modelin bu sınıfı 'duyamamasına' yol açmaktadır.

Üçüncüsü, kayıp fonksiyonunun çoğunluk yönünde toplaması. Train setinde Sarı %65, Yeşil %30, Kırmızı %4 dağılımıyla; standart cross-entropy gradyanı çoğunluk yönünde optimize edilmektedir. Yeşil sınıfı, görece az sıklıkta görülen bir azınlık olarak baskılanmaktadır.

Bu sorunun ele alınması için iki aşamalı bir yapı önerilebilir: ilk aşamada 'Yeşil mi değil mi?' binary kararını veren BERTürk-base bir sınıflandırıcı, ikinci aşamada Sarı/Kırmızı arasındaki ayrımı LLM ile yapmak. Bu yaklaşım Yeşil sınıfının özelliklerini açıklayan bir alt görev olarak daha temiz öğrenme dinamikleri sağlayabilir.

7. TARTIŞMA

7.1. Boyut-Performans Dengesi

Çalışmanın en somut bulgularından biri, 1,5 milyar parametrelili Qwen2.5 modelinin 360 milyon parametrelili SmolLM2'ye kıyasla Macro-F1 değerinde 0,146 mutlak fark üretmesidir (0,244 → 0,390). Buna karşın yaklaşık 2 milyar parametrelili Gemma-4-E2B'nin Macro-F1 değeri (0,256), 1,5 milyar parametrelili Qwen ile aynı seviyededir; bu durum sadece parametre sayısının değil, eğitim süresinin (Gemma 1 epoch, Qwen 2 epoch) ve eğitim dağılımının (Gemma'nın MoE-vari uzman seçim kapasitesinin Türkçe medikal görevde tam olarak aktive olamadığı) belirleyici olduğunu göstermektedir. Sonuç olarak Türkçe medikal görevde tek başına model kapasitesi yeterli değildir; eğitim verisi ve veriye uyarlanmış mimari de en az kapasite kadar önemlidir.

7.2. LoRA-bf16 ve QLoRA Karşılaştırması

Aynı hiperparametrelerle eğitilen Qwen2.5-1.5B modelinin QLoRA (89,2 dk, eval_loss 1,662) ve LoRA bf16 (35,6 dk, eval_loss 1,615) yapılandırmaları karşılaştırıldığında bf16 LoRA'nın 2,5 kat daha hızlı eğitilebildiği ve daha düşük eval kaybına ulaştığı gözlenmiştir. Bu sonuç, 12 GB VRAM ortamlarında 1,5 milyar parametre seviyesinde model için QLoRA'nın gerekli olmadığı; bf16 yapılandırmasının hem hız hem kalite avantajı sağladığını ortaya koymaktadır. QLoRA'nın asıl değeri, 8 GB VRAM altındaki ortamlarda veya 7+ milyar parametrelili modellerde belirginleşmektedir.

7.3. Sınıf Dengesizliği Müdahalesi Üzerine

Veri seviyesinde uygulanan oversampling müdahalesi, FNR-Red değerini 1,000'den 0,529'a düşürmüştür. Ancak bu değer halen klinik kabul edilebilirlik eşiğinin (literatürde <5-10) çok üzerindedir. Bu durum, oversampling'in tek başına yeterli olmadığını ve loss seviyesinde ek müdahalelere ihtiyaç olduğunu göstermektedir.

Önerilen iyileştirmeler şunlardır: (i) Class-weighted cross-entropy ile minority sınıf gradyan ağırlığının artırılması (Kırmızı için 5-10 kat, Yeşil için 2-3 kat); (ii) Focal loss uygulanarak kolay örneklerin gradyandan azaltılması; (iii) Doğrusal birleştirme yerine ardışık iki aşamalı sınıflandırma ile Yeşil-vs-rest kararının ayrı ele alınması; (iv) Geri çeviri (back-translation) ile Kırmızı sınıfı için sentetik örnek üretimi.

Bu önerilerden ikisinin (class-weighted CE ve focal loss) entegre edilmesinin Kırmızı recall değerini %70-80 aralığına taşıyabileceği literatür sonuçlarına dayanan bir hipotezdir. Klinik kabul eşiğinin (>%90) sağlanabilmesi için ise (i)-(iv) müdahalelerin yanı sıra doktor doğrulamalı etiketlemeye dayanan ek Kırmızı veri toplanması zorunludur.

7.4. Cascade Negatif Bulgusu Üzerine

Cascade mimarisinin tek model Qwen-balanced ile aynı sonuçları üretmesi başlangıçta beklenmedik bir sonuçtur. İki bağımsız müdahale (Gemma yeniden eğitim + prompt format düzeltme) sonrasında sonuç değişmemiştir. Bunun temel sebebi, cascade tasarımının erken durdurma mantığının (L1 'Yeşil' derse durur) çalışmamasıdır; çünkü hem L1 (SmolLM2) hem L2 (Qwen-balanced) ilk değerlendirmede Yeşil

sınıfını tahmin edememektedir. Sonuç olarak her örnek L3 katmanına eskale olmakta ve L3 'ün kararı Qwen-balanced'in tek başına verdiği karar ile aynı olmaktadır.

Cascade'in gerçekten faydalı olabilmesi için confidence-aware bir tasarım gereklidir. Örneğin her katmanın çıktısı için model logit'lerinden hesaplanan softmax entropisi kullanılarak düşük güvenli kararlar bir sonraki katmana eskale edilebilir. Ayrıca L3 modelinin daha güçlü bir mimari olması (örneğin Llama-3-8B veya Qwen2.5-7B) cascade'in katma değerini artırabilir; ancak bu durumda VRAM bütçesi 24 GB üzerine çıkmakta ve tüketici donanımı sınırını aşmaktadır.

7.5. Edge Cihaz Uygunluğu

Model boyutu ve VRAM açısından SmolLM2-360M (peak 0,87 GB) Raspberry Pi sınıfı cihazlarda 4-bit INT4 nicelendirme ile çalıştırılabilir; ancak Macro-F1 değeri (0,244) klinik kullanım için yetersizdir. Qwen2.5-1.5B (peak 3,28 GB) bir akıllı telefon veya küçük bir kiosk cihazında (ör. Jetson Orin Nano) çalışabilir ve Macro-F1 değeri (0,390 dengeli yapılandırma ile) edge uygulamalar için kabul edilebilir bir başlangıç noktasıdır. Gemma-4-E2B (peak 10,42 GB) yalnızca masaüstü GPU veya bulut altyapısında çalışabilir; bu da MoE-vari mimarinin sunduğu edge optimizasyon vaadinin Türkçe medikal görevde pratikte tam olarak gerçekleşmediğini göstermektedir.

7.6. Klinik Dağıtım Olan Mesafe

Çalışmanın en şeffaf değerlendirmesi şudur: önerilen sistem klinik bir araç değil, bir araştırma prototipidir. Bu prototipin klinik kullanıma hazır hâle getirilebilmesi için asgari aşağıdaki adımlar tamamlanmalıdır:

6. Doktor doğrulamalı en az 2.000 örneklik bir test seti hazırlanması.
7. FNR-Red <%10 hedefinin sağlanması (mevcut %53).
8. Yeşil sınıfının F1 değerinin >0,50 seviyesine çıkarılması.
9. Çoklu tohum (en az 3 farklı seed) ile istatistiksel anlamlılık testlerinin yapılması.
10. TF-IDF ve mBERT-based baseline modelleri ile karşılaştırma yapılması.
11. Klinik etik kurul onayı ve veri yerelliği denetimi.
12. A/B testi ile gerçek dünya kullanıcı kabulüne ilişkin verinin toplanması.

Bu adımların tamamı tek bir dönemlik proje kapsamına sığmamakta; ancak çalışma bu yol haritasının ilk basamağını ortaya koymakta ve gelecek çalışmalar için sayısal bir başlangıç noktası sağlamaktadır.

8. SINIRLAMALAR

Çalışmanın bilimsel iddialarının yorumlanmasında dikkate alınması gereken sınırlamalar aşağıda şeffaflıkla raporlanmıştır:

- Tek tohum (seed=42): Tüm deneyler tek bir rastgele tohum ile yapılmıştır. Standart sapma değerleri raporlanmamış; istatistiksel anlamlılık testleri uygulanmamıştır. Çalışmanın tekrarlanabilirliği seed sabitlenmesi ile sağlanmış olsa da varyans tahminleri için en az üç farklı tohum gerekmektedir.
- Kural tabanlı etiket: Test ve doğrulama kümesi dahil tüm etiketler kural tabanlı bir sistemle üretilmiştir. Doktor doğrulaması yapılmamıştır. Bu durum etiket gürültüsünün değerlendirme sonuçlarında gölgelenmesine yol açmaktadır.
- Test seti büyüklüğü: 553 toplam örnek, 34 Kırmızı vaka. Nadir sınıflarda ölçülen metrikler geniş güven aralıklarına sahiptir; FNR-Red değişiminin istatistiksel anlamlılığı ölçülmemiştir.
- Baseline eksikliği: TF-IDF + lojistik regresyon, mBERT-based ya da BERTürk-based sınıflandırıcı gibi klasik baselineler ile karşılaştırma yapılmamıştır. SLM müdahalesinin klasik yöntemlere kıyasla katma değerinin sayısallaştırılabilmesi için bu karşılaştırma ileride zorunlu hâle gelecektir.
- Yeşil sınıfı çözülmedi: Dokuz yapılandırmanın hiçbirisi Yeşil sınıfını anlamlı şekilde öğrenememiştir. Bu sorun ayrı bir alt çalışma olarak ele alınmayı hak etmektedir.
- FNR-Red hala yüksek: %52,9 değer, klinik kabul edilebilirlik eşiğinin (literatürde <%5–10) çok üzerindedir. Sistem bu hâliyle klinik uygulamada kullanılmamalıdır.
- Tek merkezli veri: Eğitim ve değerlendirme verisi tek bir kaynaktan (doktorsitesi) alınmıştır. Çoklu merkezli veri ile dağılım değişikliklerinin etkisi test edilmemiştir.
- İngilizce-Türkçe paralellik: Modellerin önceden eğitiminde Türkçe medikal metnin oranı raporlanmamıştır. Sonuçların İngilizce eşdeğer görevle karşılaştırılması bu çalışmada yapılmamıştır.
- Cascade hipotezi tam olarak test edilmedi: Confidence-aware routing varyantı, daha güçlü L3 modeli (örn. Qwen2.5-7B) ile cascade ve 3+ epoch Gemma yeniden eğitim hipotezleri zaman bütçesi nedeniyle bu çalışmaya dahil edilmemiştir.

9. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışma, Türkçe doğal dilde ifade edilen hasta semptomlarına dayalı tıbbi triaj ve bölüm yönlendirme görevini, üç farklı küçük dil modeli üzerinde sistematik olarak değerlendirmiştir. Dokuz değerlendirme yapılandırması ile elde edilen anahtar bulgular şunlardır: (i) zero-shot performans yetersizdir; (ii) basit fine-tuning sınıf dengesizliği nedeniyle Sarı sınıfa çöker; (iii) temiz oversample ile Kırmızı sınıfı kısmen yakalanmaya başlanmıştır; (iv) cascade mimarisi mevcut tasarım altında katma değer üretmemiştir.

Pratik tavsiye olarak, edge cihazlarda 3,3 GB VRAM ile çalışabilen Qwen2.5-1.5B BALANCED yapılandırması, 1,4 saniye gecikme ve %0,000 FGR değeriyle araştırma prototipi düzeyinde uygun bir başlangıç noktasıdır. Ancak FNR-Red'in halen %52,9 olması, bu modelin klinik dağıtım için olgunlaşmadığını göstermektedir.

Gelecek alıřmalar  ana ynde planlanmıřtır. Birincisi, kayıp seviyesinde sınıf dengesizlięi mdahaleleri (focal loss, aęırlıklandırılmıř CE) entegre edilecek ve Kırmızı recall'unun %80+ seviyesine tařınması hedeflenecektir. İkincisi, Yeřil sınıfını ęrenebilen iki ařamalı bir sınıflandırma yapısı (BERTrk-based binary + LLM Sarı/Kırmızı) tasarlanacaktır. ncs, doktor doęrulamalı yeni bir test setinin (hedef n=2.000) inřa edilmesi ve mevcut model performansının bu kme zerinde yeniden deęerlendirilmesi planlanmaktadır.

Akademik yayın aısından, bu alıřma ders kapsamında planlanan ortak benchmark makalesinin ("Small Language Models for Turkish NLP: A Fine-Tuning Benchmark") tıbbi triaj alt grevini temsil edecek řekilde tasarlanmıřtır. Standart sonu tablosu (Tablo 5.6) protokole uygun olarak tamamlanmıř; ortak makaleye doęrudan kaynak teřkil edebilecek bir veri yapısı sunulmuřtur. Bireysel yayın olarak ise FGR ve FNR-Red odaklı klinik gvenlik deęerlendirmesi ile cascade negatif bulgu erevesi, arařtırma prototipi dzeyinde bir bildiri iin yeterli zgnlk barındırmaktadır.

KAYNAKLAR

- [1] Manchester Triage Group. (2014). Emergency Triage. 3rd Edition. BMJ Books, London.
- [2] Wuerz, R. C., et al. (1998). Reliability and validity of a new five-level triage instrument. *Annals of Emergency Medicine*, 32(2), 236–242.
- [3] Christ, M., et al. (2010). Modern triage in the emergency department. *Deutsches Ärzteblatt International*, 107(50), 892–898.
- [4] Levin, S., et al. (2018). Machine-learning-based electronic triage more accurately differentiates patients with respect to clinical outcomes compared with the emergency severity index. *Annals of Emergency Medicine*, 71(5), 565–574.
- [5] Lee, J., et al. (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4), 1234–1240.
- [6] Alsentzer, E., et al. (2019). Publicly available clinical BERT embeddings. *NAACL ClinicalNLP Workshop*.
- [7] Gu, Y., et al. (2021). Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1), 1–23.
- [8] Singhal, K., et al. (2023). Large language models encode clinical knowledge. *Nature*, 620, 172–180.
- [9] Saab, K., et al. (2024). Capabilities of Gemini Models in Medicine. *arXiv:2404.18416*.
- [10] Schweter, S. (2020). BERTurk: BERT models for Turkish. *Zenodo*.
<https://doi.org/10.5281/zenodo.3770924>
- [11] Hugging Face. (2024). SmolLM2-360M Model Card.
<https://huggingface.co/HuggingFaceTB/SmolLM2-360M>
- [12] Yang, A., et al. (2024). Qwen2.5 Technical Report. *arXiv:2412.15115*.
- [13] Google DeepMind. (2024). Gemma 4 Technical Report.
<https://deepmind.google/technologies/gemma/>
- [14] Hu, E., et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. *ICLR 2022*.
- [15] Dettmers, T., et al. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. *NeurIPS 2023*.
- [16] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- [17] Lin, T.-Y., et al. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision*, 2980–2988.
- [18] Liu, Z., et al. (2024). LLM Cascade: Cost-effective and reliable inference. *arXiv:2404.10630*.
- [19] Shazeer, N., et al. (2017). Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *ICLR 2017*.

- [20] Bayram, A. (2023). doktorsitesi: Turkish doctor-patient Q&A dataset. Hugging Face.
<https://huggingface.co/datasets/alibayram/doktorsitesi>
- [21] Bayram, A. (2024). turkish-hospital-medical-articles. Hugging Face.
<https://huggingface.co/datasets/alibayram/turkish-hospital-medical-articles>
- [22] Dönmez, T. B. (2024). TUSGPT-TR-Medical-Dataset-v1. Hugging Face.
<https://huggingface.co/datasets/turkerberkdonmez/TUSGPT-TR-Medical-Dataset-v1>
- [23] Mangrulkar, S., et al. (2022). PEFT: State-of-the-art Parameter-Efficient Fine-Tuning methods.
<https://github.com/huggingface/peft>
- [24] von Werra, L., et al. (2023). TRL: Transformer Reinforcement Learning.
<https://github.com/huggingface/trl>
- [25] Doğuser Yazar. (2023). Turkish Medical Emergency Triage Dataset. Kaggle.
<https://www.kaggle.com/datasets/doguseryazar/turkish-medical-emergency-triage-dataset>

EKLER

EK A. Tam Hiperparametre Listesi

Parametre	SmolLM2-360M	Qwen QLoRA	Qwen LoRA bf16	Qwen BAL	Gemma-4
Önceden eğitilmiş model	HuggingFaceTB/SmolLM2-360M	Qwen/Qwen2.5-1.5B	Qwen/Qwen2.5-1.5B	Qwen/Qwen2.5-1.5B	google/gemma-4-E2B
Eğitim verisi	train.jsonl	train.jsonl	train.jsonl	train_balanced.jsonl	train.jsonl
Epoch	3	2	2	2	1
Effective batch	16	16	16	16	16
batch_size	8	4	2	2	1
grad_accum	2	4	8	8	16
learning rate	3e-4	2e-4	2e-4	2e-4	1e-4
max_length	768	896	896	896	512
lora_r	16	16	16	16	8
lora_alpha	32	32	32	32	16
lora_dropout	0,05	0,05	0,05	0,05	0,05
use_4bit (QLoRA)	True	True	False	False	True
target_modules	q,k,v,o,gate,up,down	q,k,v,o,gate,up,down	q,k,v,o,gate,up,down	q,k,v,o,gate,up,down	all-linear
packing	False	False	False	False	True
seed	42	42	42	42	42
scheduler	cosine	cosine	cosine	cosine	cosine
warmup_ratio	0,03	0,03	0,03	0,03	0,03

Tablo A.1. Tam hiperparametre listesi.

EK B. Model Kartları

EK B.1 — SmolLM2-360M FT (QLoRA)

Model adı	smollm2_360m_qlora
Kaynak	HuggingFaceTB/SmolLM2-360M (Apache 2.0)
Görev	Türkçe medikal triaj + bölüm yönlendirme

Eğitim verisi	doktorsitesi 5k → train.jsonl (n=3.972, K=4,1%)
İnce ayar yöntemi	QLoRA 4-bit nf4, r=16, α=32, dropout=0,05
Eğitim süresi	62,3 dk (RTX 4070)
Final eval_loss	1,625
Test Acc / Macro-F1 / FNR-Red / FGR	0,562 / 0,244 / 1,000 / 0,000
Inference latency (avg / p95)	1.706 ms / 3.062 ms
Model boyutu	21 MB (adapter)
Bilinen limitasyonlar	Bölüm yönlendirme yetkin değil (acc 0,103). Yeşil ve Kırmızı sınıfları öğrenilmemiş. Edge cihaz uyumlu ancak klinik kabul eşiklerinin altında.
Çalıştırma gereksinimleri	≥1 GB RAM, herhangi bir tüketici GPU veya CPU. Inference için 4-bit nicelendirme ile mobil cihaza taşınabilir.

EK B.2 — Qwen2.5-1.5B FT (LoRA bf16)

Model adı	qwen25_15b_lora_nobnb
Kaynak	Qwen/Qwen2.5-1.5B (Apache 2.0)
Görev	Türkçe medikal triaj + bölüm yönlendirme
Eğitim verisi	doktorsitesi 5k → train.jsonl (n=3.972)
İnce ayar yöntemi	LoRA bf16, r=16, α=32, dropout=0,05
Eğitim süresi	35,6 dk
Final eval_loss	1,615
Test Acc / Macro-F1 / FNR-Red / FGR	0,624 / 0,256 / 1,000 / 0,000
Inference latency	1.463 ms
Model boyutu	85 MB (adapter)
Bilinen limitasyonlar	Sınıf dengesizliği nedeniyle Sarı sınıfa çökmüş; Yeşil ve Kırmızı sınıfları üretilmemiş.
Çalıştırma gereksinimleri	≥3,3 GB VRAM, BF16 destekli GPU.

EK B.3 — Qwen2.5-1.5B BALANCED (LoRA bf16)

Model adı	qwen25_15b_lora_balanced
Kaynak	Qwen/Qwen2.5-1.5B
Görev	Türkçe medikal triaj + bölüm yönlendirme

Eğitim verisi	train_balanced.jsonl (n=4.458, K=14,5% — 4× oversample)
İnce ayar yöntemi	LoRA bf16, r=16, α=32
Eğitim süresi	~36 dk
Final eval_loss	1,617
Test Acc / Macro-F1 / FNR-Red / FGR	0,618 / 0,390 / 0,529 / 0,000
Inference latency	1.407 ms
Model boyutu	85 MB (adapter)
Bilinen limitasyonlar	Yeşil sınıfı F1 = 0. FNR-Red %53 ile klinik eşik üzerinde. Bu çalışmadaki en güçlü tek modeldir; klinik dağıtım için yetersizdir.
Çalıştırma gereksinimleri	≥3,3 GB VRAM, BF16 destekli GPU.

EK B.4 — Gemma-4-E2B FT (QLoRA)

Model adı	gemma4_e2b_qlora
Kaynak	google/gemma-4-E2B (Apache 2.0)
Görev	Türkçe medikal triaj + bölüm yönlendirme
Eğitim verisi	train.jsonl (n=3.972)
İnce ayar yöntemi	QLoRA 4-bit, r=8, α=16, packing=True
Eğitim süresi	42,8 dk
Final eval_loss	1,460 (en düşük)
Test Acc / Macro-F1 / FNR-Red / FGR	0,624 / 0,256 / 1,000 / 0,000
Inference latency	2.733 ms
Model boyutu	70 MB (adapter)
Bilinen limitasyonlar	Yalnızca 1 epoch eğitildiği için kapasite eksik kullanılmış olabilir. Peak VRAM 10,4 GB ile edge cihaz limitlerini zorluyor. Bölüm doğruluğu en yüksek olmasına rağmen triaj sınıflandırmasında Sarı'ya çökmüştür.
Çalıştırma gereksinimleri	≥10 GB VRAM, BF16 + 4-bit destekli GPU.

EK C. Prompt Şablonları

EK C.1 — Eğitim ve Inference Prompt Şablonu (3 alanlı):

Görev

Aşağıdaki hasta semptom metnini analiz et. Triaaj seviyesini (Yeşil/Sarı/Kırmızı) ve en uygun tıbbi bölümü belirle. Cevabını SADECE geçerli bir JSON objesi olarak ver.

Semptom

<HASTA METNİ>

Cevap

{"triaaj": "...", "bolum": "...", "neden": "..."}
EK C.2 — Cascade v1 Prompt (4 alanlı, format uyumsuzluğu nedeniyle ABANDONE):

Görev

<L3 instruction>

Semptom

<HASTA METNİ>

Ön-Analiz

{prev_l1_l2_json}

Cevap

EK C.3 — Cascade v2 Prompt (3 alanlı, eğitimle uyumlu):

Görev

Aşağıdaki hasta semptom metnini analiz et. Önceki ön-analiz sonucu: {prev_triage}, {prev_bolum}. Triaaj seviyesini ve bölümü kararlaştır.

Semptom

<HASTA METNİ>

Cevap

EK D. Reproducibility Index

Artefakt	Yol
Etiketleyici	scripts/label_data.py
Triaaj kuralları	configs/triage_rules.json
Eğitim/test bölme	scripts/split_and_format.py
Sınıf dengeleme	scripts/balance_train.py
Eğitim scripti	train/qlora_train.py
Eğitim konfigürasyonları	configs/ {smollm2,qwen25,qwen25_lora,qwen25_lora_balanced,gemma4,gemma4_balanced}.json

Tek model deęerlendirme	eval/evaluate.py
Cascade deęerlendirme	eval/cascade_eval.py
Sonu JSON'ları	eval/results/*_results.json
Tahmin JSONL'ları	eval/results/*_predictions.jsonl
Eęitim logları	logs/qwen25_train.log
Confusion matrix vb.	eval/plots/
Bu rapor	Final_Rapor_Tibbi_Triaj.docx
řekiller	figures/fig01_*.png ... fig18_*.png
GitHub repo (planlanan)	<a href="https://github.com/<organizasyon>/medical-triage-tr">https://github.com/<organizasyon>/medical-triage-tr

Tablo D.1. Reproducibility index. Tm artefaktlar seed=42 ile yeniden retilir.

Yeniden retim adımları:

13. `scripts/sample\_data.py` ile 5.000 rneklik altkme oluřturulur.
14. `scripts/extract\_triage\_rules.py` ile Kaggle veri kmesinden anahtar kelime szlę retilir (configs/triage_rules.json).
15. `scripts/label\_data.py` ile etiketleme yapılır (data/labeled/labeled_all.jsonl).
16. `scripts/split\_and\_format.py` ile train/val/test blmleri oluřturulur.
17. `scripts/balance\_train.py` ile train_balanced.jsonl retilir.
18. `python train/qlora\_train.py --config configs/<config>.json` ile her model eęitilir.
19. `python eval/evaluate.py --tag <tag> --model\_id <hf-id> --adapter <adapter-path>` ile her model deęerlendirilir.
20. `python eval/cascade\_eval.py --tag <tag>` ile cascade deęerlendirmesi alıřtırılır.
21. `python build\_figures.py` ile řekiller (PNG) yeniden retilir.
22. `python build\_report.py` ile DOCX raporu derlenir.